## Progetto di Sicurezza Informatica e Internet

### Progetto A2 - Encrypted 2D Barcodes

Giovanni Rossi - gio.rossi.1991@gmail.com Pasquale Verlotta - pasquale.verlotta@gmail.com



## Indice

In	$\operatorname{dice}$		Ι
$\mathbf{El}$	enco	delle figure	II
1	Intr	oduzione	1
	1.1	Scopo del progetto	1
	1.2	Tecnologie Utilizzate	3
		1.2.1 Strumenti di sviluppo	3
		1.2.2 Linguaggio e librerie utilizzate	3
	1.3	Le principali tecnologie	4
		1.3.1 QR-Code	5
		1.3.2 OCR	5
2	Pro	gettazione	7
	2.1	Requisiti	7
	2.2	Architettura	9
	2.3	Gestione della sicurezza	12
3	Test		13
	3.1	Funzionamento dell'applicazione	13
	3.2	Test Sperimentali	13
4	Con	clusioni	14
$\mathbf{A}$	Mar	nuale di installazione	15

# Elenco delle figure

1.1	Esempio di QR-Code	
1.2	OCR	6
2.1	Use Case Diagram	8
2.2	Architettura del sistema	(

## Introduzione

### 1.1 Scopo del progetto

Il progetto sviluppato in questi mesi per il corso di "Sicurezza Informatica e Internet" si propone come scopo quello di realizzare un'applicazione che permetta di gestire un documento cartaceo in forma sicura. In particolare questo significa che chi utilizza tale sistema deve essere in grado di

- compilare un foglio con informazioni sensibili;
- cifrare tutto o alcune parti del foglio al fine di poterlo inviare a chiunque voglia;
- decifrare il contenuto di un documento ricevuto da un'altra persona.

Lo scopo ultimo è dunque quello di abilitare l'utilizzatore ad inviare ad un gruppo di persone il documento che ha appena creato. Tuttavia durante il trasferimento (funzione che non compete a questa applicazione) può succedere che il documento possa venire alterato in alcune sue parti se non si utilizzano canali sicuri; moltissime truffe avvenute in passato si sono basate su questa vulnerabilità. Dunque uno degli scopi è quello di garantire con opportune tecniche basate su crittografia asimmetrica che il documento cartaceo resti robusto ed inattaccabile qualunque sia il canale di comunicazione che l'utente finale sceglie per l'invio. Nel caso di questo progetto, l'elaborazione riguarda documenti cartacei, quindi non è possibile archiviare le informazioni sensibili in una qualche struttura dati. La sfida più importante è quella di trasportare insieme al documento stampato le informazioni segrete. Questo apre una serie di problematiche legate alla gestione delle informazioni che sono in formato digitale nella fase di composizione e diventano analogiche nella fase di acquisizione di un documento spedito (che può essere stampato

e acquisito più volte durante il percorso - per esempio via fax). La tecnologia migliore per il trasporto dei dati su immagini è rappresentata dal *QR-Code*, un particolare tipo di codice a barre 2D che può contenere al suo interno una discreta quantità di informazioni. I dati possono essere riletti utilizzando algoritmi di riconoscimento robusti che hanno raggiunto nel tempo un elevata maturità. Nell'ambito di questo progetto i QR-Code sono stati utilizzati sia per memorizzare le informazioni cifrate, sia per apporre una firma digitale al documento intero. Si risponde così alle esigenze di mantenere segreti alcuni contenuti e di rendere il documento robusto alle manipolazioni esterne.

Un'altra funzionalità importante che rientra negli scopi di questa applicazione, è quella di creare una gerarchia tra gli utenti che accedono al servizio. Può capitare, infatti, di voler pubblicare un certo documento e di voler permettere solo a pochi eletti di accedere alle informazioni cifrate. Questo implica che nel sistema si avranno utenti con livelli di privilegio diversi dove ognuno di questi può decifrare e leggere solo le informazioni adeguate al suo livello. In questo caso la soluzione più ovvia potrebbe essere quella di pubblicare versioni diverse dello stesso documento oscurando opportunamente sulle diverse copie le informazioni che si vogliono tenere segrete a ciascun gruppo. Questo processo può risultare lungo, macchinoso e poco sicuro: è possibile, infatti, che qualche copia possa finire al destinatario sbagliato se non si prendono opportune precauzioni. Ci si è quindi occupato di realizzare un sistema dove la cifratura viene effettuata con chiavi speciali (che da ora in poi verranno chiamate chiavi di livello), le quali vengono distribuite solo agli utenti che hanno un livello di fiducia (o Trust Level) adeguato. In questo caso un Trust Level basso corrisponde ad un basso livello di privilegio, mentre un Trust Level alto garantisce l'accesso a tutte le informazioni cifrate con le chiavi di livello più basso.

Riassumendo quindi, per quanto riguarda le funzionalità principali, il sistema dovrebbe permettere di:

- compilare un documento contenente qualsiasi tipo di informazione;
- cifrare in tutto o in parte il documento appena scritto;
- allegare le informazioni cifrate al documento stesso così che il o i destinatari possano leggerlo;
- firmare il documento in modo tale che il mittente non possa ripudiarne la provenienza e i destinatari possano accorgersi di eventuali manomissioni durante il trasferimento;
- specificare diversi livelli di privilegio gerarchici per la lettura delle informazioni.

### 1.2 Tecnologie Utilizzate

Gli obiettivi appena illustrati, danno un'idea delle tante problematiche che l'applicazione deve affrontare. Per questo sono molte le tecnologie che sono state messe in gioco. Nel seguito di questo paragrafo verranno spiegate quelle utilizzate maggiormente.

#### 1.2.1 Strumenti di sviluppo

Per quanto riguarda gli strumenti, si è fatto uso di

- Eclipse Luna come IDE per la gestione del progetto e dei file sorgente;
- Apache Maven v2.2 per la gestione delle dipendenze e del ciclo di vita dell'applicazione;
- **Git** per il *versioning* e la condivisione dei sorgenti nel team (in particolare si è usato un repository pubblico<sup>1</sup> su *GitHub* come piattaforma online di condivisione<sup>2</sup>);

### 1.2.2 Linguaggio e librerie utilizzate

In questo progetto è stato utilizzato Java come linguaggio di programmazione principale. I motivi di questa scelta ricadono principalmente su:

- il paradigma Object-Oriented che ha permesso l'utilizzo di architectural e creational pattern per risolvere le problematiche più comuni, come Façade, Factory Method, Abstract Factory, DAO e Singleton che sono stati ampiamente utilizzati nello sviluppo;
- l'alta manutenibilità del codice;
- la portabilità su altre piattaforme diverse da quella di sviluppo;
- la grande quantità di librerie presenti a supporto degli obiettivi descritti prima.

Per quanto riguarda invece i singoli moduli del software sviluppato, si sono utilizzati diversi framework e librerie. Per la parte di sicurezza c'è:

<sup>&</sup>lt;sup>1</sup>Per certi versi si è seguito il principio di Auguste Kerckhoffs secondo cui "in un sistema crittografico è importante tener segreta la chiave, non l'algoritmo di crittazione".

<sup>&</sup>lt;sup>2</sup>Link del repository:https://github.com/WAFcoding/ProgettoSicurezza.git

- JCA/JCE (Java Cryptographic Architecture/Java Criptographic Extension) come framework e provider dei principali algoritmi di cifratura, firma e hashing;
- BouncyCastle che si integra con JCA/JCE e fornisce un maggior numero di algoritmi di cifratura e firma nonché funzioni di generazione di certificati;

Per il modulo di elaborazione dei documenti:

- ImageMagik per la manipolazione delle immagini dei documenti acquisiti per la decodifica;
- ZXing per la generazione e lettura di QR-Code (in generale supporta molti tipi di codici a barre sia 1D che 2D);
- iTextPDF per la generazione di documenti ad alta risoluzione ed il posizionamento preciso di testo e QR-Code nel documento;
- Tesseract ed in particolare il wrapper Java Tess4J per il recupero del testo dopo la scansione dei documenti.

Per la parte di persistenza invece si è fatto uso di:

- MySQL come database relazionale per il sistema di *provisioning* delle chiavi e la gestione degli utenti;
- SQLite per la gestione dei dati locali di ogni singolo utente (sotto forma di database cifrato);
- Hibernate come framework per la gestione dei database (MySQL e SQLite), ed in particolare il modulo ORM (Object-Relational Mapping).

### 1.3 Le principali tecnologie

Di seguito una breve panoramica dello stato dell'arte delle tecnologie utilizzate maggiormente nello sviluppo di questo progetto. Si analizzeranno in particolar modo il **QR-Code** e l'**OCR**.

#### 1.3.1 QR-Code

Il QR-Code (Quick Response Code in virtù del fatto che il codice fu sviluppato per permettere una rapida decodifica del suo contenuto) è un codice a barre bidimensionale, ossia a matrice, composto da moduli neri disposti all'interno di uno schema di forma quadrata. Viene impiegato per memorizzare informazioni generalmente destinate a essere lette tramite un dispositivo mobile. In un solo codice QR possono essere contenuti oltre 7089 caratteri numerici o 4296 alfanumerici. Il QR-Code fu sviluppato nel 1994 dalla compagnia giapponese Denso Wave allo scopo di tracciare le componenti di automobili nelle fabbriche della Toyota. Vista la capacità del codice di contenere più dati di un codice a barre venne in seguito utilizzato per la gestione delle scorte da diverse industrie. Tuttavia essendo un codice che deve essere riportato su un documento cartaceo, può subire dei danni che possono provocare degli errori nella seguente lettura. Per questo viene utilizzato il codice Reed-Solomon per la rilevazione e correzione d'errore che permette di ricostruire i dati persi, ripristinando, durante la decodifica, fino al 30% delle informazioni codificate.



Figura 1.1: Un esempio di QR-Code.

#### 1.3.2 OCR

La parola OCR (Optical Character Recognition) descrive una classe di sistemi di riconoscimento ottico dei caratteri. Gli OCR sono programmi dedicati alla conversione di un'immagine contenente testo, solitamente acquisite tramite scanner (come nel caso di questo progetto), in testo digitale modificabile con un normale editor. Il testo può essere convertito in formato ASCII semplice, Unicode o, nel caso dei sistemi più avanzati, in un

#### 1.3. LE PRINCIPALI TECNOLOGIE

formato contenente anche l'impaginazione del documento. L'OCR è un importante campo di ricerca dell'intelligenza artificiale, della visione artificiale e del pattern recognition, legati al riconoscimento delle immagini. I sistemi OCR per funzionare correttamente richiedono una fase di "addestramento". Durante questa fase al sistema vengono forniti degli esempi di immagini col corrispondente testo in formato ASCII o simile in modo che gli algoritmi si possano calibrare sul testo che usualmente andranno ad analizzare. Gli ultimi software di OCR utilizzano algoritmi in grado di riconoscere i contorni e in grado di ricostruire oltre al testo anche la formattazione della pagina. Gli OCR possono essere usati per riconoscere:

- caratteri stampati, per i quali gli algoritmi noti hanno un tasso di errore del 1%;
- scrittura a mano libera, problema tutt'altro che risolto, per la quale gli algoritmi hanno tassi di accuratezza dell'80% 90%;
- caratteri in corsivo, che è un campo in fase di studio, per il quale si hanno tutt'oggi risultati poco soddisfacenti a livello di accuratezza.



Figura 1.2: Processo da seguire per utilizzare un sistema OCR.

## Progettazione

In questo capitolo verranno analizzate in dettaglio le scelte progettuali che hanno permesso la realizzazione del sistema software. Dopodiché si analizzerà, attraverso la rappresentazione dei diagrammi **UML**, la definizione delle fasi di sviluppo, ossia la progettazione delle funzionalità correnti dell'applicazione.

### 2.1 Requisiti

Come primo aspetto della progettazione si analizzeranno adesso i requisiti del sistema. Innanzitutto si deve specificare che l'intero sistema è pensato per essere utilizzato in un ambito amministrativo dove gli utenti possono essere per esempio i dipendenti di un'azienda. Questo vuol dire che ci si trova in un sistema chiuso in cui le persone che usano il sistema sono note. Tuttavia è possibile che nel tempo i dipendenti si licenzino oppure che ne sopraggiungano di nuovi, quindi deve essere presente una procedura che consenta di inserire nuovi utenti ed eventualmente di rimuovere quelli esistenti. In questo sistema dove gli utenti sono noti, immaginiamo la presenza di un utente **amministratore** che agisce come supervisore ed è l'unico ad avere la facoltà di abilitare gli utenti all'utilizzo del servizio nonché di assegnare il *Trust Level*.

Di seguito viene mostrato il diagramma dei casi d'uso che rappresenta una vista generale delle funzionalità che il sistema deve avere.

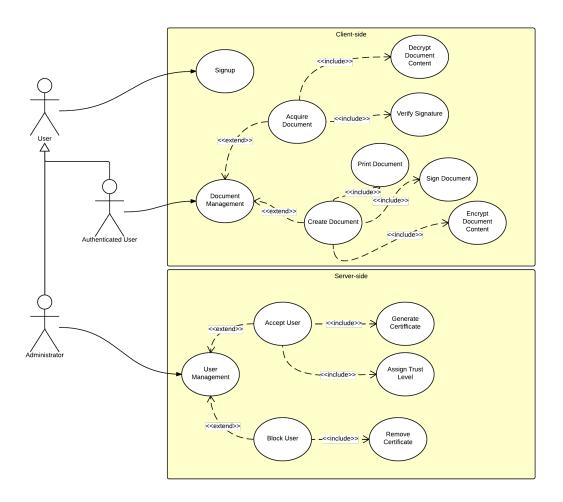


Figura 2.1: Diagramma dei casi d'uso del sistema software realizzato

La prima cosa che va evidenziata è che il tutto è strutturato secondo un architettura di tipo client/server. Questi due componenti dialogano tra di loro utilizzando una connessione sicura basata su SSL<sup>1</sup>. Da quello che si può evincere, il server è un componente fondamentale che espone la funzionalità di provisioning delle chiavi. Esso mantiene sia le chiavi di livello necessarie per la cifratura del documento, sia le chiavi pubbliche degli utenti registrati al sistema.

Da quello che si può vedere dalla figura 2.1 nel sistema si hanno 3 attori importanti: l'amministratore, l'utente registrato (autenticato) e l'utente

<sup>&</sup>lt;sup>1</sup>Dettagli maggiori saranno dati nel paragrafo 2.3.

semplice che non ha mai utilizzato il sistema. Come è stato già detto, l'amministratore si occupa di gestire l'accesso degli utenti. Questo vuol dire che ha piena facoltà di abilitare gli utenti all'utilizzo del sistema verificandone l'identità con procedure interne all'azienda che possono variare di caso in caso e che esulano completamente dagli scopi di questo progetto. Oltre a questo può decidere di limitare l'accesso al sistema bloccando l'utente con una semplice procedura, grazie alla quale il server è in grado di comprendere se l'utente che si connette è autorizzato oppure no ad ottenere le chiavi di un certo livello. Altro compito fondamentale è quello dell'assegnazione del Trust Level che viene deciso in fase di abilitazione dell'utente al sistema. Tuttavia questo può essere anche cambiato successivamente. Grazie al Trust Level, l'utente sarà abilitato a conoscere solo i segreti per cui è stato autorizzato, quindi l'assegnazione di questo parametro è fondamentale e richiede la massima attenzione.

L'utente registrato (o come riportato in figura 2.1 "autenticato") rappresenta una qualsiasi persona che è stata abilitata dall'amministratore ad usare l'applicazione in tutte le sue funzionalità attuali. Un utente di questo tipo dispone di una coppia di chiavi asimmetriche RSA a 1024 bit e di un certificato X.509 che viene utilizzato per le connessioni al server che richiedono mutua autenticazione. L'utente autenticato ha la possibilità di comporre un documento, oscurarlo in alcune sue parti utilizzando le chiavi di livello a cui può accedere, e firmarlo con la propria chiave privata RSA. Naturalmente oltre alla composizione del documento, l'utente registrato ha anche la facoltà di leggere quello che è stato inviato a lui o agli utenti con il suo stesso Trust Level<sup>2</sup>.

Per quanto riguarda l'utente semplice, si è sicuramente notato che questo ha l'unica facoltà di registrarsi al sistema. Questo perché non dispone ancora di un certificato da usare per l'autenticazione e quindi non ha alcuna possibilità di leggere le informazioni se non provando ad eseguire un attacco sulla sicurezza del sistema o del documento cartaceo.

#### 2.2 Architettura

Data una panoramica dei requisiti e delle funzionalità principali del sistema, si passerà adesso ad analizzare più in dettaglio l'architettura del sistema realizzato.

<sup>&</sup>lt;sup>2</sup>Si rimanda al paragrafo 2.3 per una trattazione più approfondita di questo aspetto.

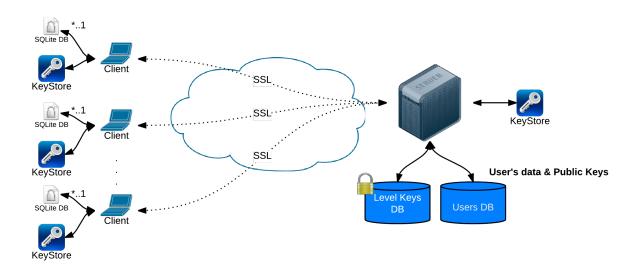


Figura 2.2: In questa figura sono rappresentate le componenti del sistema software realizzato.

Quella mostrata in figura 2.2 è l'architettura del sistema che è stato realizzato per questo progetto. Come si può vedere (anche da quanto già accennato nei paragrafi precedenti) il sistema si compone di due applicazione separate: un server e un client. Entrambe queste applicazioni comunicano con il protocollo TCP/IP con l'aggiunta del layer di sicurezza realizzato da SSL.

Per quanto riguarda il server esso offre 2 servizi differenti. Il primo (sulla porta 8888) che richiede che gli utenti in connessione confermino la loro identità inviando il loro certificato così come previsto dallo standard SSL quando il server richiede, come requisito nella fase di handshake, il certificato del client al fine di verificare la mutua autenticazione. Le funzionalità offerte da questo primo servizio sono:

- fornire le chiavi di livello agli utenti autenticati che le richiedono (purché ne abbiano diritto in base al loro livello di fiducia);
- fornire le chiavi pubbliche degli utenti registrati al sistema, così che gli utenti possano verificare le firme digitali apposte sui documenti cartacei.

Il secondo servizio (sulla porta 8889) non richiede invece autenticazione mutua, in quanto è quello che permette agli utenti nuovi di comunicare i loro dati al server al fine di richiedere un'abilitazione all'utilizzo del sistema.

Da come si può vedere in figura 2.2 il server dispone di una connessione a due database MySQL separati e ad un Java KeyStore<sup>3</sup>. Il KeyStore serve a memorizzare i certificati degli utenti, in modo che possano essere identificati univocamente nella fase di handshake della connessione. Il primo dei due database si occupa di gestire le chiavi di livello necessarie per la cifratura del documento. Le chiavi sono memorizzate cifrate con AES tramite una chiave robusta e ad ognuna di queste è associato il livello di fiducia relativo. L'altro database si occupa di mantenere le informazioni degli utenti registrati, comprese le loro rispettive chiavi pubbliche. Si è deciso di separare i due database in quanto essi devono soddisfare requisiti di sicurezza differenti in quanto dalla segretezza delle chiavi di livello (che dovrebbero essere cambiate periodicamente) dipende la robustezza dell'intero sistema di cifratura dei documenti. La separazione permetterebbe allora di ospitare su server differenti i due database, che sarebbero quindi protetti con password robuste e differenti e con l'aggiunta di altri sistemi di sicurezza, quali VPN e Firewall, per la protezione da attacchi esterni.

All'applicazione stand-alone lato client compete invece tutta la gestione dei documenti, ossia la cifratura, la firma e la decifrazione delle immagini. Dal diagramma dell'architettura si vede come anche questo componente presenti una connessione ad un KeyStore e a diversi database di tipo SQLite. Per quanto riguarda il KeyStore, questo assolve alla stessa funzione di quello del server, ossia mantiene il certificato pubblico del server e la chiave privata di ciascun utente insieme al suo rispettivo certificato. Ogni entry del KeyStore (che nella pratica non è altro che una mappa indicizzata per una stringa chiamata alias) è cifrata con la password personale di ciascun utente. In più anche il file del KeyStore stesso è cifrato con una master key. I database SQLite, invece, servono a memorizzare i dati locali di ciascun utente compresa anche la coppia di chiavi asimmetriche RSA. Ogni utente ha il proprio database personale cifrato con la sua password. Il motivo di questa scelta riguarda soprattutto il fatto che i database SQLite non sono altro che file binari che sono gestiti da un software molto leggero (dimensioni nell'ordine delle centinaia di KByte). Quindi possono essere manipolati molto meglio rispetto per esempio ad un file di configurazione personalizzato per cui si sarebbe dovuta implementare una logica di gestione. Quindi la facilità di gestione e la leggerezza sono stati i principali responsabili di questa scelta.

<sup>&</sup>lt;sup>3</sup>Un Java KeyStore (JKS) è un repository di certificati pubblici e chiavi utilizzato per la cifratura dei pacchetti su connessioni SSL.

### 2.3 Gestione della sicurezza

Dopo aver trattato in dettaglio dell'architettura del sistema, si può passare a descrivere tutte le procedure che sono state implementate per gestire la sicurezza del sistema e dei documenti cartacei.

## Test

- 3.1 Funzionamento dell'applicazione
- 3.2 Test Sperimentali

Conclusioni

# Appendice A

Manuale di installazione